Homework

M SEKOUA

November 2019

Exercice 1

Soit Y_i un echantillon aléatoire simplke d'une loi exponentiele avec une fonction de densité de probabilité :

$$f(y_i|\theta) = \frac{1}{\theta}e^{-\frac{y_i}{\theta}}, \ y_i, \theta \in \mathbb{R}_+$$

Trouvez la distribution a posteriori de δ

Soit $\delta = \theta^{-1}$ et soit un a priori sur δ spécifié comme une distribution Gamma avec les hyperparamètres α_0 et β_0 où $\pi(\delta) \propto \delta^{\alpha_0 - 1} e^{-\frac{\delta}{\beta_0}}$. Par definition de l aposteriori,on a $\pi(\delta|y) \propto f(y|\delta)\pi(\delta)$. Donc en injectant la densité dans notre approximation, nous obtenons :

$$\pi(\delta|y) \propto \delta e^{-\delta y} \times \delta^{\alpha_0 - 1} e^{-\frac{\delta}{\beta_0}}$$
$$\propto \delta^{\alpha_0} e^{-\delta(y + \frac{1}{\beta_0})}$$

Donc $\delta | y \leadsto \mathcal{G}(\alpha_0 + 1, \frac{1}{y + \frac{1}{\beta_0}})$

Pour un echantillon de taille n, alors on a alors

$$\delta|y \rightsquigarrow \mathcal{G}(\alpha_0 + n, \frac{1}{(\sum_{i=1}^n y_i) + \frac{1}{\beta_0}})$$

Trouvez la distribution a posteriori de θ

On sait que $\delta \leadsto \mathcal{G}(\alpha_0, \beta_0)$ donc $\theta \leadsto \mathcal{IG}(\alpha_0, \frac{1}{\beta_0})$. Pour une facilité de lecture et de manipulation, nous posons $\delta_0 = \frac{1}{\beta_0}$

$$\pi(\theta|y) \propto f(y|\theta)\pi(\theta)$$

 $\propto (\frac{1}{\theta})^{\alpha_0+2}e^{-\frac{y+\delta_0}{\theta}}$

Donc $\theta|y \rightsquigarrow \mathcal{IG}(\alpha_0 + 1, y + \delta_0)$

Pour un echantillon de taille n, alors on a alors

$$\theta|y \rightsquigarrow \mathcal{IG}(\alpha_0 + n, \sum_{i=1}^n y_i + \delta_0)$$

Derivons l'estimateur Bayesien $\tilde{\theta}$ de θ

Pour une fonction de coût quadratique, l'estimateur bayésien $\tilde{\theta}(y)$ est défini comme suit :

$$\tilde{\theta}(y) = \arg\min_{d} \rho(\pi, d|y)$$

où $\rho(\pi, d|y) = \int_{\Theta} (\theta - d)^2 \pi(\theta|y) d\theta$.

Comme l'a posteriori de θ est une inverse gamma, alors les moments d'ordre 1, 2 sont definis. Egalement la marginale de m(x) est bien definie et intégrable des lorsque l'on a $\alpha_0 + n > 2$.

La fonction de coût est convexe et donc admet un minimum. Donc notre fonction $\rho(\pi, d|y)$ admet un minimum.

L'estimateur bayésien pour une a priori donné, verifie la condition suivante

$$\frac{\partial \rho}{\partial \delta}(\pi, \delta, y)\Big|_{\delta = \tilde{\theta}} = 0$$

D'où

$$\tilde{\theta}(y) = \int_{\Theta} \theta \pi(\theta|y) d\theta$$
$$= \frac{\delta_0 + \sum_{i=1}^n y_i}{\alpha_0 + n - 1}$$

L'estimateur bayésien est celui ayant le cout a posteriori minimum.

Trouvez l'erreur quadratique moyen de l'estimateur Bayésien $\tilde{\theta}$

Par definition l'erreur quadratique moyen est definie comme suit :

$$EQM(\delta) = \int_{\mathcal{X}} (\delta - \theta)^2 f(y_1, ..., y_n | \theta) dy_1 dy_n$$

Remarque: On observe que $\mathbb{E}(\sum_{i=1}^{n} y_i | \theta) = n\theta$ Pour l'estimateur bayésien $\tilde{\theta}$,

$$\theta - \frac{\sum_{i=1}^{n} y_i + \delta_0}{\alpha_0 + n - 1} = \frac{n\theta - \sum_{i=1}^{n} y_i}{\alpha_0 + n - 1} + \frac{\alpha_0 - 1}{\alpha_0 + n - 1}\theta - \frac{\delta_0}{\alpha_0 + n - 1}$$

Donc

$$EQM(\tilde{\theta}) = \frac{n\theta^2}{(\alpha_0 + n - 1)^2} + \frac{(\alpha_0 - 1)^2\theta^2}{(\alpha_0 + n - 1)^2} + \frac{\delta_0^2}{(\alpha_0 + n - 1)^2} - 2\frac{(\alpha_0 - 1)\delta_0\theta}{(\alpha_0 + n - 1)^2}$$

Pour l'estimateur du maximum de vraisemblance \bar{Y} ,

$$\bar{Y} - \theta = \frac{1}{n} \sum_{i=1}^{n} (y_i - \theta)$$

Comme les y_i sont independantes et identiquement distribuées, alors

$$EQM(\bar{Y}) = \frac{\theta^2}{n}$$

Pour l'estimateur $\hat{\theta}$,

$$\hat{\theta} - \theta = \frac{1}{n+1} \sum_{i=1}^{n} (y_i - \theta) - \frac{\theta}{n+1}$$

Donc

$$EQM(\hat{\theta}) = \frac{\theta^2}{(n+1)}$$

Choix de l'estimateur apres calcul de risque quadratique moyen

Lorsque $\alpha_0 = 1$, on preferait l'estimateur $\hat{\theta}$ à partir de $n \geq 2$

Calcul du risque a posteriori des estimateurs \bar{Y} et $\hat{\theta}$

On definit le risque a posteriori comme suit :

$$\mathbb{E}^{\pi}(\delta - \theta)^2 = \int_{\Theta} (\delta - \theta)^2 \pi(\theta|y) d\theta$$

Pour $\alpha_0 = 1$,

$$\theta|y \rightsquigarrow \mathcal{IG}(n+1, \sum_{i=1}^{n} y_i + \delta_0)$$

Pour l'estimateur $\tilde{\theta}$, on a

$$\mathbb{E}^{\pi}(\tilde{\theta} - \theta)^{2} = \frac{(\sum_{i=1}^{n} y_{i} + \delta_{0})^{2}}{n^{2}(n-1)^{2}}$$

Pour l'estimateur du maximum de vraisemblance $\bar{Y},$ on a donc :

$$\mathbb{E}^{\pi}(\bar{Y} - \theta)^2 = \frac{(\sum_{i=1}^{n} y_i + \delta_0)^2}{n^2(n-1)^2} + \frac{\delta^2}{n^2}$$

Pour l'estimateur $\hat{\theta}$,

$$\mathbb{E}^{\pi}(\hat{\theta} - \theta)^2 = \frac{(\sum_{i=1}^n y_i + \delta_0)^2}{n^2(n-1)^2} + (\frac{1}{n+1}\bar{Y} + \frac{\delta}{n})^2$$

Le meilleur risque au sens du risque bayesien est l'estimateur bayesien $\tilde{\theta}$

Exercice 2

Soit $y_1, ..., y_T$ une série chronologique de reponses de comptage indépendentes, générées de la façcon suivante :

$$y_t|\gamma, \delta, \lambda \sim \begin{cases} \mathbb{P}_o(\gamma) & \text{si } t \leq \lambda \\ \mathbb{P}_o(\delta) & \text{si } t > \lambda \end{cases}$$

On suppose de plus que

$$\gamma \leadsto \mathcal{G}(a_1, a_2)$$

 $\delta \leadsto \mathcal{G}(d_1, d_2)$
 $\lambda \leadsto \mathcal{U}_{1...T}$

Derivons la fonction de vraisemblance pour ce modèle

Definissons la vraisemblance

$$l(y|\gamma, \delta, \lambda) = (\prod_{t=1}^{\lambda} \mathbb{P}_o(y_t|\gamma)) (\prod_{t=\lambda+1}^{T} \mathbb{P}_o(y_t|\delta)) 1_{y_t \in \mathbb{N}}$$
$$= (\prod_{t=1}^{\lambda} \gamma^{y_t} \frac{e^{-\gamma}}{y_t!}) (\prod_{t=\lambda+1}^{T} \delta^{y_t} \frac{e^{-\delta}}{y_t!}) 1_{\min_t y_t \in \mathbb{N}}$$

On a les paramètres γ , δ car λ correspond plutôt à un paramètre de changement de changement. Nous derivons donc la log-vraisemblance par rapport γ et δ .

La log-vraisemblance vaut donc :

$$\mathcal{L}(y|\gamma, \delta, \lambda) = -\sum_{t=1}^{T} \log(y_t!) + \sum_{t=1}^{\lambda} (y_t \log(\gamma) - \lambda \gamma) + \sum_{t=\lambda+1}^{T} (y_t \log(\delta) - \delta(T - \lambda))$$

$$\nabla_{\gamma,\delta} \mathcal{L}(y_t | \gamma, \delta,) = 0$$

$$\hat{\gamma} = \frac{\sum_{t=1}^{T} y_t}{\lambda}$$

$$\hat{\delta} = \frac{\sum_{t=\lambda+1}^{T} y_t}{T - \lambda}$$

Decrire l'algorithme de Gibbs

Pour definir l'algorithme de gibbs, nous avons besoin de definir l'a posteriori $\pi(\gamma, \delta, \lambda|y_t)$ qui nous permettra d'obtenir de determiner les lois des parametres γ , δ et λ , lorsque l'on calcule l a posteriori

$$\pi(\gamma, \delta, \lambda | y_t) \propto f(y_t | \gamma, \delta, \lambda) \pi(\gamma, \delta, \lambda)$$

$$\propto (\prod_{t=1}^{\lambda} \gamma^{y_t} \frac{e^{-\gamma}}{y_t!}) (\prod_{t=\lambda+1}^{T} \delta^{y_t} \frac{e^{-\delta}}{y_t!}) \gamma^{a_1 - 1} e^{-a_2 \gamma} \delta^{d_1 - 1} e^{-d_2 \delta} \frac{1}{T}$$

$$\propto \gamma^{\sum_{t=1}^{\lambda} y_t + a_1 - 1} e^{-\gamma(\lambda + a_2)} \delta^{\sum_{t=\lambda+1}^{T} y_t + d_1 - 1} e^{-\delta(T - \lambda + d_2)}$$

Donc pour implementer l'algorithme de Gibbs, on obtient donc


$$\gamma \leadsto \mathcal{G}(\sum_{t=1}^{\lambda} y_t + a_1, \lambda + a_2)$$

$$\delta \leadsto \mathcal{G}(\sum_{t=\lambda+1}^{T} y_t + d_1, T - \lambda + d_2)$$

$$\lambda \leadsto Categorical(\frac{\gamma^{\sum_{t=1}^{\lambda} y_t + a_1 - 1} e^{-\gamma(\lambda + a_2)} \delta^{\sum_{t=\lambda+1}^{T} y_t + d_1 - 1} e^{-\delta(T - \lambda + d_2)}}{\sum_{\lambda=1}^{T} \gamma^{\sum_{t=1}^{\lambda} y_t + a_1 - 1} e^{-\gamma(\lambda + a_2)} \delta^{\sum_{t=\lambda+1}^{T} y_t + d_1 - 1} e^{-\delta(T - \lambda + d_2)}})$$

Detection du point de changement

Nous avons simulé les variables du changement de point, des parametres gamma et delta.



La moyenne de la variable λ est 41.65 et l'ecart type de la variable λ est 2.84. Donc les changements sont autour de la valeur 42.

Le nombre prevu d'accident avant 2.49 et le nombre d'accident apres est de 0.88.